

sndsTools


Un package R simplifiant l'extraction de données SNDS

Matthieu Doutreligne
Insee
2026-06-04

merci à Antoine Belloir and Marc Dibbling (ICM, équipe Aramis)

SNDS sources

Janvier 2016 : création par la loi « modernisation de notre système de santé »



🚀 **2021:** Accès permanent à la recherche (INRIA, INSERM, hôpitaux...) : profil 108 et formation

En résumé, le SNDS est une base riche

Base de donnée populationnelle

✓ ≈ 68 millions individuals

...mais complexe et
centrée sur les remboursements

Informations non disponibles

- ✗ Résultats d'examen
- ✗ Données cliniques (IMC, pression artérielle, médicaments peu coûteux en hospitalisation...)
- ✗ Expositions environnementales (tabac, alcool, nutrition, ...)
- ✗ Données socio-économiques (éducation, revenu, ...)
- ✗ Pas de motifs de consultations



Données de ville (DCIR)

- ✓ Consultations
- ✓ Actes médicaux
- ✓ Examens médicaux
- ✓ Médicaments et dispositifs médicaux (remboursés uniquement)



Hospitalisation (PMSI)

- ✓ Séjours
- ✓ Actes et diagnostics
- ✓ Consultations externes



Causes de décès

- ✓ Diagnostics des certificats de décès




Données patient

- ✓ Variables démographiques (âge, sexe, commune de résidence, date de naissance et de décès, indice de déprivation sociale)
- ✓ Statut Affection de Longue Durée
- ✓ Classification des dépenses identifiée par la Cnam ("cartographie des pathologies")




Typologie des études basées sur le SNDS (ICM)


Etudes descriptives



Décrire le statut de santé d'une population ...et identifier les facteurs associés




Incidence de Parkinson en France sur 10 ans



Caractéristiques associées à la maladie d'Alzheimer

Etudes comparatives (thérapeutiques)


Comparer l'efficacité de différents traitements



Survie pour deux options de traitement pour la maladie de Parkinson (N=20 000)

Etudes pronostiques

Prédire la progression d'une maladie à partir de caractéristiques individuelles



Courbes ROC pour l'apparition de démence (prédictions à 2, 5 et 10 ans)

Description of healthcare practices


Eg. Practice of screening pregnant women for CMV infection (2022-2023)

Années 2022 et 2023

NABM 1260 : IgG and IgM anti-CMV


Heterogeneity of practices on the french territory

- Frequent use (> 40%) :
 - Île-de-France, Corse, Grand Est
- Much less common ($\approx 15\%$) :
 - Bretagne, Normandie, Hauts-de-France, Auvergne-Rhône-Alpes




Impact of institutional recommendations


Eg. Proton pump inhibitor dispensing trends in children under 1 year of age since 2015 (⚠️ WIP)




A sanity check in SNDS clinical studies : visualize individual treatment pathways



Chaîne de traitement typique




Exemple :



Chaîne de traitement typique

Data Richness : A Blessing and a Curse

Complex Data Structure



- Finding relevant variables
- Finding relevant tables
- Gathering, consolidating and reconciling data
- Looping over partially yearly indexed tables

Complex Data

- Tables containing (>200 columns and >100M lines)
 - Filtering often required prior collection
- Managing duplicates, fictional data, errors, inconsistencies, date formats
- Specialized & Technical jargon

Technical hurdles

Limited data storage,
Limited R Package availability

User's Guide:



428 pages long with
excerpt code and
crucial information to
work correctly with
SNDS data

Challenging for new users & many sources of errors (even for experienced ones...)

Ressources utiles de documentation

Dictionnaire interactif

<https://health-data-hub.shinyapps.io/dico-snds/>

Afficher 50 résultats

Rechercher diagnost

? Aide 9 clés de jointure Partager la vue

Table	Variable	Libelle	Nomenclature
T_MCOaaB	DGN_PAL	Diagnostic principal (DP)	MS_CIM_V
T_MCOaaB	DGN_REL	Diagnostic relié (DR)	MS_CIM_V
T_MCOaaB	NBR_DGN	Nombre de diagnostics associés significatifs (nDAS) dans ce RSA	-

Résultats 1 à 3 sur une liste de 3. (filtered from 5,004 total entries)

Précédent 1 Suivant

Variable DGN_PAL, Diagnostic principal (DP)

Type : string (6.0)

Historique :

- Date de création : 2005
- Date de suppression : NaN

[Vous pouvez proposer une correction ou un complément à cette adresse.](#)

Nomenclature : MS_CIM_V

Copy CSV Afficher 50 résultats

Rechercher

CIM_COD	CIM_LIC	CIM_LIL	MVT_D
G400	EPILEP, IDIOP, DEFINIS PAR LEUR	Epilepsie et syndromes épileptiques idiopathiques définis par leur	

La documentation collaborative

Documentation collaborative du SNDS

Bienvenue sur la documentation collaborative du Système National des Données de Santé.

Cette documentation est en construction, via [ce dépôt GitLab](#).

Contributeurs

Cette documentation est maintenue par le Health Data Hub.

Elle résulte d'une mise en commun de documents et travaux par plusieurs organisations, dont :

- la Caisse nationale d'assurance maladie - [Cnam](#)
- le Health Data Hub - [HDH](#)
- Le Ministère des Solidarités et de la Santé: la Direction de la Recherche, des études, de l'évaluation et des statistiques - [DREES](#)
- les Agences régionales de santé - [ARS](#)
- Santé publique France - [SpF](#)
- la Direction de la Sécurité Sociale - [DSS](#)
- l'Agence Technique de l'Information sur l'Hospitalisation - [ATIH](#)
- le Centre d'épidémiologie sur les causes médicales de décès - [CépiDC](#)
- l'Institut national de la santé et de la recherche médicale - [Inserm](#)
- la Haute Autorité de Santé - [HAS](#)

<https://documentation-snds.health-data-hub.fr/snds/>

Le forum

SNDS

Documentation Dico Meetup S'inscrire Se connecter

catégories étiquettes Récents Top Catégories

Catégorie	Sujets
Annonces Nous publions ici des informations à destination de la communauté : événements, nouveautés sur les outils, ouvertures de poste, etc. Conseil : activer l'option Surveiller sur cette catégorie.	113
FAQ La FAQ est un catalogue de questions-réponses. Posez ici vos questions, et aider la communauté en proposant des réponses. Appel à projet 2 Health Data Hub AAP-DAIAE	412
AAP GD4H - HDH	85
Documentation collaborative Nous discutons dans cette catégorie de la Documentation du SNDS , un site internet de documentation que nous éditons collaborativement via GitHub.	44
FAQ - AMI BOAS	3
AMI Unibase [Archivé] Dans le cadre de la seconde vague de l'Appel à Manifestation d'Intérêt UNIBASE, en collaboration avec Unicancer et la Ligue nationale contre le cancer, le Health Data Hub propose une FAQ pour répondre au mieux à vos interrogations.	1
Divers	133


<https://entraide.health-data-hub.fr/categories>

Ressources de code existantes pour le SNDS

Plusieurs institutions utilise la base SNDS et ont des bases de code interne construit pendant plusieurs années, mais **rarement publiques**.




BOAS (PDS) : des références utiles d'étude
Code SAS ad-hoc nécessitant peu configurable, pas de cohérence entre études




<https://gitlab.com/healthdatahub/boas/>

Outils_SNDS (Drugs-Safe-R) : développé activement, beaucoup de choses, cohérence correcte entre scripts
Tout en sas, limitant configuration et bonnes pratiques logicielles



https://gitlab.com/Drugs-Safe-R/Outils_SNDS

Scalpel : Initiatives ouverte pour une base de code partagée
Non adaptée à l'infrastructure partagée (actuelle) et difficilement extensible



<https://github.com/X-DataInitiative/SCALPEL-Flattening>

Et d'autres initiatives individuelles
Non maintenues, utilisées par de rares personnes, peu d'efforts logiciels (ex. notebooks)


- combicancer (<https://gitlab.com/healthdatahub/boas/institut-curie/combicancer>), Institut Curie
- pysnds (github.com/GuyomardMarie/pysnds/), Aix-Marseille University
- sndskit (<https://github.com/Epiconcept-Paris/sndskit>)

Ressources de code existantes pour le SNDS

A ce jour, pas de base de code pour de nouveaux acteurs SNDS sur la plateforme historique de la CNAM

le + proche : outils_SNDS (Drugs-Safe-R)

Conséquences pour les chercheurs individuels



- Réinvention de la roue pour des fonctionnalités basiques
- Ré-implementations typiquement
 - compromis entre qualité et temps
 - sous optimisées
 - Sujettes à erreur et approximation

Temps passé à créer son dataset >> temps restant pour l'analyse


Ressources de code existantes pour le SNDS

A ce jour, pas de base de code pour de nouveaux acteurs SNDS sur la plateforme historique de la CNAM

le + proche : outils_SNDS (Drugs-Safe-R)


Conséquences pour les équipes de recherche, la statistique publique et les agences de santé

- Barrières à l'entrée $\Rightarrow$ moins d'acteurs utilisant ces données
- Efforts dupliqués $\Rightarrow$ gaspillage d'argent et de temps
- Manque d'uniformité et de reproductibilité pour les datasets SNDS datasets $\Rightarrow$ recherche de moins bonne qualité



Le paquet sndsTools : Objectifs

-  Améliorer la reproductibilité entre études
-  Amélioration de la documentation existante
-  Faciliter l'arrivée de nouveaux arrivants
-  Accélérer l'extraction de données pour tous
-  Encourager le partage de code et la transparence
-  Apports communautaires



Le paquet sndsTools : Historique

- 2024 :
 - Organisation d'un atelier [R-SNDS au congrès d'épidémiologie Emoïs](#)
 - Formaliser de besoins : Collaboration, formation / prise en main R, codes d'extractions basiques
 - Echange de code entre HAS, ICM, AP-HM : début de sndsTools
- 2025-2026 :
 - Utilisation et développement par Insee / ICM
 - Intérêts CNAM, Inria, Epiphare, SpF : recherche de financement en cours

⚙️ Fonctionnalités : Qu'y a-t-il dans sndsTools à ce jour ?

Références

<https://sndstoolers.github.io/sndsTools/reference/index.html>

- Des fonctions d'extraction basiques
- Un utilitaire pour les **identifiants patients**
- Toutes les fonctions sont **testées** sur données fictives et SNDS

Package index

Extraction SNDS

Fonctions pour extraire les données de soins individuelles à partir du SNDS.

`extract_consultations_erprsf()`

Extraction des consultations dans le DCIR.

`extract_drug_dispenses()`

Extraction des délivrances de médicaments.

`extract_drug_erucdf()`

Extrait les dispensations de médicaments en accès précoces depuis le DCIR.

`extract_hospital_consultations()`

Extraction des consultations externes à l'hôpital (MCO).

`extract_hospital_stays()`

Extraction des diagnostics des séjours hospitaliers (MCO).

`extract_long_term_disease()`

Extraction des Affections Longue Durée (ALD)

Utilitaires

Fonctions utilitaires pour manipuler les données extraites.

`retrieve_all_psa_from_idt()`

Gestion des identifiants patients à l'aide de `BEN_IDT_ANO`

`retrieve_all_psa_from_psa()`

Gestion des identifiants patients à l'aide de `BEN_NIR_PSA`



Axe documentaire

https://sndstoolers.github.io/sndsTools/reference/extract_consultations_erprsf.html

- **API constante** d'une fonction à l'autre
- **Documentation** des :
 - Paramètres
 - Sorties
 - Filtres et choix SNDS
 - Liens vers les références si existantes
- [roxygen2](#) permet la gestion dans un seul fichier de la documentation et du code

Extraction des consultations dans le DCIR.

Source: [R/extract_consultations_erprsf.R](#)

Cette fonction permet d'extraire les consultations dans le DCIR. Les consultations dont les dates `EXE_SOI_DTD` sont comprises entre `start_date` et `end_date` (incluses) sont extraites.

Usage

```
extract_consultations_erprsf(  
  start_date,  
  end_date,  
  pse_spe_filter = NULL,  
  prestation_filter = NULL,  
  dis_dtd_lag_months = 6,  
  patients_ids_filter = NULL,  
  output_table_name = NULL,  
  conn = NULL  
)
```

Arguments

start_date

Date. La date de début de la période des consultations à extraire.

On this page

Usage

Arguments

Value

Details

Examples



Prise en main : Utilisation sur le portail CNAM

<https://sndstoolers.github.io/sndsTools/articles/sndsTools.html>

Copier/coller le fichier `sndsTools.R`

- **Sur votre ordinateur (local)** : Télécharger [le fichier `sndsTool.R` contenant toutes les fonctions du paquet disponible sur github](#) ; l'ouvrir et copier son contenu (ctrl+c)
- **Sur le portail CNAM** : coller le contenu de ce fichier dans un nouveau script R `sndsTools.R` (ctrl+v) puis dans votre fichier d'étude charger les fonctions : `source("sndsTools.R")`



Bientôt : paquet installé par la CNAM

Prise en main

Source: [vignettes/sndsTools.Rmd](#)

A quoi sert ce paquet R de traitement de données ?

Ce paquet R de traitement de données a pour objectif de faciliter l'accès aux données du Système National des Données de Santé (SNDS) pour les utilisateurs de R. Il permet de simplifier les extractions de données et de mettre à disposition des fonctions implémentant les bonnes pratiques pour utiliser ces données.

Prise en main rapide

Installation

Sur le portail CNAM

Il est nécessaire de copier/coller le code source du paquet sur le portail CNAM. Pour cela, il faut suivre les étapes suivantes :

- En local (sur votre ordinateur) : Télécharger [le fichier `sndsTool.R` de la dernière release du paquet disponible sur github](#). Celui-ci contient toutes les fonctions du paquet.
- En local, ouvrir le fichier `sndsTool.R` et copier tout son contenu.
- Sur le portail CNAM, coller le contenu de ce fichier dans un nouveau script R `sndsTools.R`.
- Sur le portail CNAM, charger toutes les fonctions du paquet: `source("sndsTools.R")`

NB: La version la plus à jour de `sndsTools.R` (entre deux releases) est disponible comme artifact [sur le dépôt GitHub sur la page de l'action](#). Attention, cette version peut être instable, il est recommandé d'utiliser une release stable du paquet.

En local (pour le développement du paquet uniquement)

Ouvrir le paquet avec Rstudio, puis lancer :

```
devtools::install(dependencies = TRUE)
```

Puis pour charger le paquet :

```
library(sndsTools)
```

Axe apprentissage : un tutoriel avec un exemple (simpliste) d'étude

https://sndstoolers.github.io/sndsTools/articles/tutoriel_avc.html

- Patients hospitalisés en MCO pour AVC
- Démo des fonctions d'extraction
- Le code tourne de façon identique sur :
 - Le portail CNAM
 - La documentation (données fictives)



Documentation et code identiques

```
# Définir la période d'étude - année 2024
start_date <- as.Date("2024-01-01")
end_date <- as.Date("2024-12-31")

# Codes CIM-10 pour les AVC
codes_avc <- c("I61", "I62", "I63", "I64")

# Extraire les séjours avec diagnostics d'AVC
extract_hospital_stays(
  start_date = start_date,
  end_date = end_date,
  dp_cim10_codes_filter = codes_avc,
  or_dr_with_same_codes_filter = TRUE, # Inclure les diagnostics reliés
  or_da_with_same_codes_filter = FALSE, # Exclure diagnostics associés similaires
  and_da_with_other_codes_filter = FALSE, # Exclure diagnostics associés différents
  da_cim10_codes_filter = NULL, # Pas de filtre sur diagnostics associés
  patients_ids_filter = NULL, # Extraire tous les patients
  output_table_name = "TMP_SEJOURS_AVC", # Stocker en table Oracle
  conn = conn
)
#> Results saved to table TMP_SEJOURS_AVC in Oracle.
#> NULL

# Récupérer un aperçu des données
sejours_avc_head <- dplyr::tbl(conn, "TMP_SEJOURS_AVC") |>
  head(5) |>
  dplyr::collect()

kable(sejours_avc_head)
```

ETA_NUM	RSA_NUM	SEJ_NUM	SEJ_NBJ	NBR_DGN	NBR_RUM	NBR_ACT	ENT_MOI
190076	3	3	10	3	2	6	7



Prise en main : Développement en local

<https://sndstoolers.github.io/sndsTools/articles/sndsTools.html#utilisation>

Installation

Ouvrir le paquet avec Rstudio, puis lancer :

```
devtools::install(dependencies = TRUE)
```

Puis pour charger le paquet :

```
library(sndsTools)
```

Chargement de données synthétiques

```
# Télécharge les données synthétiques du SNDS et les charge dans une base DuckDB.
# On se limite à la table ER_PRS_F pour gagner du temps.
# Pour avoir toute la base synthétique, enlever l'argument subset_tables ou le mettre à NULL.
conn <- connect_synthetic_snds(
  subset_tables = c(
    "ER_PRS_F"
  ),
  force_insert = TRUE
)
#> INFO [2026-05-12 14:18:48] Creating database at: /home/runner/.cache/sndsTools/synthetic_snds.du
#> INFO [2026-05-12 14:19:01] All files downloaded and extracted to: /home/runner/.cache/sndsTools
#> INFO [2026-05-12 14:19:03] Successfully loaded 2 tables: ER_PRS_F, user_synonyms
DBI::dbListTables(conn)
#> [1] "ER_PRS_F"      "user_synonyms"
```

Exemple basique d'extraction de données (consultations de chirurgie vasculaire)

```
consultations_df <- extract_consultations_erprsf(
  conn = conn,
  start_date = as.Date("2011-01-01"),
  end_date = as.Date("2019-12-31"),
  pse_spe_filter = c(48)
)
#> Extracting consultations
#> from all specialties among
#> 48...
consultations_df |> knitr::kable()
```

BEN_NIR_PSA	EXE_SOI_DTD	PSE_SPE_COD	PFS_EXE_NUM	PRS_NAT_REF	PRS_ACT_QTE	B
-------------	-------------	-------------	-------------	-------------	-------------	---

PEyUrNJzINkmgxwUz	2019-12-23	48	HKcvLcRye	2132	1	
-------------------	------------	----	-----------	------	---	--



Prochaines étapes

- Opportunité de parallélisation / réécrire la logique de boucle : [#PR76](#) issue [#92](#)
- Intégration des autres champs PMSI : HAD, SSR
- Traduction / intégration des codes SAS de Drugs-Safe-R
- Extension à d'autres champs du SNDS :
biologies (DCIR et PMSI), CCAM (DCIR et PMSI), top pathologies, ALD, indemnités journalières (DCIR), médicaments hors GHS (PMSI) ([#79](#)) ...
- 🤔 A la recherche de contributeurs :
<https://github.com/SNDStoolers/sndsTools/issues>
 - Idées
 - Documentation
 - Revue de code
 - Code

Différente manière de contribuer

Répondre à une question sur une issue

De nombreuses questions sont posées sur les [issues](#). Vous pouvez y répondre en donnant des conseils, ou en proposant une solution.

Créer une nouvelle issue

Si vous avez trouvé un bug, ou si vous avez une question sur une fonctionnalité, vous pouvez [créer une nouvelle issue](#).

En cas de bug, il est important de donner un exemple reproductible [re-prex](#). Celui-ci contient le code nécessaire pour reproduire le bug, et le message d'erreur complet. Il est très important pour qu'un développeur plus expérimenté puisse comprendre le problème et vous aider.

Contribuer à la documentation

Contribuer à la documentation est aussi important que de contribuer au code. Vous pouvez proposer des modifications à la documentation en créant une [pull request](#). Les petites erreurs et modifications peuvent être corrigées directement dans l'interface web GitHub.

NB: La documentation est principalement dans le code R, et est générée avec le paquet [roxygen2](#). Pour la modifier il faut donc modifier les fichiers `.R` dans le dossier `R/` du projet.

Contribuer au code

Afin de résoudre un bug, ou d'ajouter une nouvelle fonctionnalité, vous pouvez créer une [pull request](#).

Journées data science & open source, Insee, SSPHub

<https://ssphub.netlify.app/talk/2026-06-jdos/>

- 16 juin 2026 (9h30-17h30):
 - **Matinée** : accueil et présentation des principes de contribution à l'open source
 - **Après-midi** : séparation en groupes autour des différents projets et contributions
- 17 juin 2026 (9h-17h):
 - **Matinée** : contributions
 - **Après-midi** : contributions et clôture

Merci à tous les contributeurs !

Antoine Belloir (ICM)

Thomas Soeiro (AP-HM)

Marc Dibbling (ICM)

Leo Guillon (ICM)

Thomas Nédelec (ICM)

Judith Abecassis (Inria)

Catherine Bisquet (HAS)

Nelly Leguen (HAS)

Gladys Baudet (Drees)

Nicolas Minier (Epiphare)

Slides supplémentaires

Une comparaison R natif vs sndsTools

https://sndstoolers.github.io/sndsTools/articles/benchmark_sndstools_vs_r.html

? Est-ce qu'il y a une différence de résultats entre une requête native en R et l'utilisation de sndsTools ?


- Même résultats
- sndsTools plus lent car boucle sur les mois (bonnes pratiques CNAM)

```
source(here::here("sndsTools.R"))
conn <- connect_oracle()

t0 = Sys.time()
output_quetiapine_sndstools <- extract_drug_dispenes(
  start_date = as.Date(date_deb),
  end_date = as.Date(date_fin),
  atc_cod_starts_with_filter = atc_quetiapine,
  dis_dtd_lag_months = 6, # pour requêter les liquidations arrivant après la date de soin.
  conn = conn
)

timed_sndstool = difftime(Sys.time(), t0, units = "secs")
print(paste(
  "Temps de calcul - sndsTools : ", round(timed_sndstool), "secondes" # 162s
))
```

Nombre de dispensations de quétiapine par jour



Un benchmark de temps d'extraction

https://sndstoolers.github.io/sndsTools/articles/benchmark_dplyr_vs_rsqli.html

? Différence de temps d'extraction entre syntaxe dplyr et syntaxe sql ?

- Requête simple mais volumineuse sur ER_PRS_F, ER_PHA_F et ER_ETE_F
- Cas d'étude : Vitamin C sur différentes périodes
- Conclusion : Pas de différences !

